



# 钟李涛

求职岗位：ai应用开发

意向城市：深圳

入职时间：随时到岗

## 个人信息

年龄：22岁

性别：男

婚姻状况：未婚

身高体重：175cm/60kg

民族：汉

籍贯：广东

政治面貌：共青团员

电话：13590607258

邮箱：2119845886@qq.com

## 技能特长

### 模型训练与微调

熟练LoRA/QLoRA 等高效微调技术，能够根据特定的数据集和任务需求，对预训练模型进行针对性参数调整，提高模型的性能和适应性。

熟练基于LLaMA-Factory 框架完成适配的微调和评估。

熟练使用Xtuner 完成大模型局部微调，包括自定义数据集，训练配置的修改，模型转换与合并。

### 本地私有化部署

熟练 vLLM、LMDeploy 推理部署技术，能够将微调后的模型进行本地私有化部署。熟练 Ollama本地轻量化部署技术，支持本地模型

(Qwen/Llama3/DeepSeek) 快速简单运行推理。熟悉 OpenCompass 评测工具及自定义数据集评估，对模型进

## 教育背景

2022-09 ~ 2026-07 华南理工大学

智能科学与技术（本科）

专业成绩：GPA 3.8/4（专业前40%）

主修课程：数据挖掘、机器学习、神经网络与深度学习、模式识别

## 项目经验

### 基于 RAG 的劳动法法律助手

项目链接：<https://github.com/zhong-li-tao/project>

#### 1.1 项目背景

本项目旨在应用前沿的检索增强生成（RAG）技术，构建一个专门服务劳动纠纷法律智能问答助手。该助手能快速、精准地回答用户解除劳动合同等专业问题，提升公众获取法律信息的效率和准确性。

#### 1.2 技术方案

模型设计与优化：

1) 使用 DeepSeek-R1-Distill-Qwen-7B模型

2) 设计了基于检索增强生成（Retrieval-Augmented Generation）的 RAG 架构，系统爬取权威文本数据。

3) 对原始数据进行精细化预处理：清洗、去重、格式标准化、分段（Chunking）。

向量化与检索（Retrieval）：

1) 采用 BGE 系列模型将预处理后的文本段落编码为高维向量。利用 ChromaDB 等高效的向量数据库构建本地化知识库索引，支持快速相似度搜索。

生成（Generation）与 RAG 集成：

1) 将用户查询向量化，从向量数据库中检索出最相关的 10 个法律条文或解释片段作为上下文。

2) 使用微调后的开源大语言模型 DeepSeek-R1-Distill-Qwen-7B 模型作为生成器。

3) 设计严谨的提示词工程（Prompt Engineering），要求模型严格依据检索到的法律上下文生成简洁、准确、无歧义的回答，并明确标注答案来源依据（如法规名称、条款号）。加入拒绝回答无关或超出范围问题的机制。

技术亮点：

1) 本地化知识库深度构建：专注于劳动法和劳动合同法，构建了高质量、高时效性、覆盖全面的法律专属知识库，这是准确性的核心保障。

2) 严谨的生成约束与可解释性：通过精心设计的 Prompt，强制模型回答严格基于检索到的法律上下文，避免幻觉；生成答案自动附带来源依据（法规名称+具体条款），增强结果的可信度和用户可追溯性。

3) 领域适配与拒绝机制：模型经过微调或 Prompt 优化，能有效理解 and 处理法律领域的专业表述；并具备识别和拒绝回答与劳动法和劳动合同法或超出知识范围的问题的能力，提升服务专业性。

4) RAG 框架高效集成：熟练运用 Chromadb/LlamaIndex

等框架，实现了从数据接入、检索、提示构建到生成、输出的端到端高效 RAG 流水线。

### 多风格情绪对话助手开发

项目描述：基于大模型微调技术，独立完成「多风格情绪对话助手」全链路开发，实现「同一用户输入生成多种风格回复」的核心功能，适配不同用户情绪偏好，落地为可交互的 Web 产品。

行客观评估，并结合主观评估效果。

Agent 系统开发

熟悉使用LlamaIndex 快速构建 LLM 驱动的智能问答应用。  
熟悉使用 RAG工程化方案落地 AI 助手类项目场景，实现文档分块（Text Splitters）-向量化（BAAI/bge-large-zh-v1.5）-索引和检索（Chroma）-生成（Qwen/DeepSeek）全流程开发。  
熟悉嵌入模型原理，相似性检索，知识切片方案，检索召回率，结果重排序等 RAG 方案最佳实践，提高回复准确率，缓解大模型的幻觉问题。

熟练本地私有化部署 Dify，使用 Dify + 本地大模型 快速构建企业级智能体应用。了解基于 LangGraph 构建复杂多代理应用, 无缝集成 LangSmith 跟踪链路调用流程。熟悉 MCP 调用。

Python 技术栈

熟练掌握  
python, fastapi,sqlalchemy,pytorch 框架

计算机:



英语:



技术栈: LlamaFactory\Xtuner、vllm\ollama\LMDeploy、OpenCompass、Python、Fastapi

核心职责:

- 1.模型选型与评测：基于 OpenCompass 工具，对比 Qwen2.5-3B-Instruct 与 Qwen1.5-1.8B-Chat 模型在中文短文本理解、自然语言推理任务的性能，最终选定 Qwen2.5-3B-Instruct 作为基座模型（核心任务平均准确率 64.02%）。
- 2.数据集与模型训练：设计多风格对话数据集（含温柔、毒舌风格），通过 qLora 轻量化微调（仅训练 0.1% 参数），优化训练配置使最终 Loss 稳定在 0.035，显存占用控制在 8GB 内，训练效率达 1983 tokens/s。
- 3.模型部署与前端开发：使用 vllm 部署微调后的模型，搭建 Streamlit 可视化前端，支持用户实时输入交互，实现平均响应速度 0.8 秒的流畅体验。
- 4.性能量化与优化：设计业务指标体系，验证模型风格区分度 90%、风格纯度 85%、内容一致性 100%，确保多风格切换不跑题、差异显著。

项目成果:

- 1.完成「选型 - 训练 - 部署 - 交互」全链路落地，实现同一输入生成 2 种差异化风格回复，满足多样化情绪陪伴需求。
- 2.开发可直接演示的 Web 产品，支持实时交互，核心指标均达预期阈值，具备实际应用价值。
- 3.形成完整技术文档与演示视频，具备端到端工程落地能力。

## 自我评价

作为2026届智能科学与技术专业应届毕业生，具备扎实的AI大模型相关专业知识，熟练掌握模型微调、私有化部署、RAG工程化、Agent系统开发等核心技能，契合AI大模型工程师岗位需求。具备较强的独立项目开发能力，成功落地2个AI相关项目，熟悉大模型全链路开发流程，注重技术细节与性能优化。学习能力强，对AI大模型领域前沿技术保持高度关注，善于快速吸收新技术、解决实际工程问题。工作认真负责、严谨细致，具备良好的逻辑思维、团队协作与沟通能力，愿意深耕AI大模型领域，快速适应职场节奏，为团队创造价值。